

التقرير الفني

GF 4

تحت إشراف:

أ.ب.م/ محمد الادهم مهدي فضل

العنوان:

تصنيف المحاصيل باستخدام التعلم الآلي من خلال صور الرادار ذي الفتحة التركيبية متعددة الأوقات من القمر الصناعي

Sentinel-1

Machine Learning-Based Crop Classification Using Multi-Temporal Sentinel-1 SAR Imagery

1. المقدمة:

يُعد تحديد أنواع المحاصيل الزراعية بدقة أحد أهم التطبيقات الحديثة للاستشعار من البعد، حيث يساهم في دعم الأمن الغذائي، وإدارة الموارد الزراعية، وتقدير الإنتاج الزراعي، وتحسين كفاءة استخدام المياه، بالإضافة إلى دعم متخذي القرار في التخطيط الزراعي المستدام. وتعتمد الطرق التقليدية لتحديد أنواع المحاصيل على المسوحات الحقلية، والتي تتطلب وقتًا وجهدًا وتكاليف مرتفعة، خاصة عند دراسة مساحات زراعية واسعة.

شهدت السنوات الأخيرة تطورًا كبيرًا في استخدام بيانات الأقمار الصناعية وتقنيات الذكاء الاصطناعي في تصنيف المحاصيل الزراعية، ويعد القمر الصناعي Sentinel-1 التابع لوكالة الفضاء الأوروبية (ESA) من أهم مصادر البيانات الرادارية المستخدمة في هذا المجال. حيث يعتمد Sentinel-1 على تقنية الرادار ذي الفتحة التركيبية (Synthetic Aperture Radar - SAR) التي تتيح الحصول على صور عالية الدقة بغض النظر عن الظروف الجوية أو الغطاء السحابي أو الإضاءة، مما يجعله مناسبًا لمراقبة المحاصيل الزراعية على مدار العام.

وتتميز بيانات الرادار بحساسيتها للتغيرات في بنية النبات، والكتلة الحيوية، ومحتوى الرطوبة، وخشونة السطح، وهي خصائص تختلف من محصول إلى آخر خلال مراحل النمو المختلفة. لذلك فإن استخدام السلاسل الزمنية لصور Sentinel-1 يسمح بتمييز الأنماط الزراعية المختلفة وتحقيق دقة مرتفعة في تصنيف المحاصيل.

يعتمد هذا المشروع على منصة Google Earth Engine (GEE)، والتي توفر بيئة حوسبة سحابية متقدمة لمعالجة وتحليل كميات ضخمة من بيانات الاستشعار عن بُعد دون الحاجة إلى أجهزة ذات إمكانيات عالية. كما يعتمد المشروع على خوارزمية K-Means باعتبارها من خوارزميات التعلم الآلي المستخدمة في تصنيف البيانات الرادارية.

2. أهداف المشروع:

يهدف المشروع إلى تطوير نموذج يعتمد على التعلم الآلي لتصنيف المحاصيل الزراعية باستخدام بيانات Sentinel-1 متعددة الأزمنة داخل منصة Google Earth Engine.

وتتمثل الأهداف التفصيلية فيما يلي:

- جمع صور Sentinel-1 التي تغطي مواسم النمو بالكامل.
- إجراء المعالجة المسبقة لصور الرادار.

- إنشاء مركبات زمنية شهرية (Monthly Composites).
- استخراج الخصائص الرادارية والزمنية.
- تدريب نموذج K-Means باستخدام بيانات مرجعية.
- إنتاج خريطة رقمية لأنواع المحاصيل.
- تقييم دقة التصنيف باستخدام مصفوفة الالتباس.
- تصدير النتائج بصيغة GeoTIFF لاستخدامها في برامج نظم المعلومات الجغرافية.

3. البيانات المستخدمة

أولاً: منطقة الدراسة:

تم تحديد منطقة الدراسة داخل منصة Google Earth Engine باستخدام مضلع (Polygon) يمثل حدود المنطقة الزراعية المستهدفة، والتي تضم مجموعة متنوعة من المحاصيل الزراعية.



ثانياً: بيانات Sentinel-1

اعتمدت الدراسة على بيانات Sentinel-1 GRD المتوفرة داخل منصة Google Earth Engine، والتي تتميز بدقة مكانية تصل إلى 10 أمتار، وتوفر استقطابين (VV) و (VH) مناسبين لتحليل الغطاء النباتي.

المواصفات	العنصر
Sentinel-1A / Sentinel-1B	القمر الصناعي
COPERNICUS/S1_GRD	مصدر البيانات
رادار ذو فتحة تركيبية (SAR)	نوع المستشعر
C-Band	التردد
VH و VV	الاستقطاب
IW	نمط التصوير
10 متر	الدقة المكانية

المواصفات	العنصر
2024-2025	الفترة الزمنية

4. منهجية العمل

تتكون منهجية المشروع من عدة مراحل مترابطة كما يلي:



المرحلة الأولى: جمع البيانات

يتم استدعاء صور Sentinel-1 من منصة Google Earth Engine مع تحديد:

- منطقة الدراسة.
- الفترة الزمنية.
- نوع الاستقطاب (VH) و (VV).
- نمط التصوير IW.
- مسار القمر الصناعي (Ascending) و (Descending).

المرحلة الثانية: المعالجة المسبقة

تتضمن هذه المرحلة تحسين جودة الصور الرادارية من خلال تنفيذ العمليات التالية:

- تصحيح المدار (Orbit Correction).
- إزالة الضوضاء الحرارية.
- المعايرة الإشعاعية.
- تصحيح تأثير التضاريس.
- تقليل ضوضاء Speckle باستخدام مرشح متوسط البؤرة (Focal Mean Filter).

- تحويل قيم الرادار إلى وحدة الديسيبل (dB)

المرحلة الثالثة: التجميع الزمني

بعد المعالجة المسبقة يتم إنشاء متوسط شهري لصور Sentinel-1 لكل شهر خلال موسم النمو، مما يساعد على تقليل الضوضاء وإظهار التغيرات الموسمية للمحاصيل الزراعية.

المرحلة الرابعة: استخراج الخصائص

يتم استخراج مجموعة من الخصائص التي تساعد نموذج التعلم الآلي على التمييز بين المحاصيل المختلفة، وتشمل:

- قيم VV .
- قيم VH .
- نسبة VH/VV .
- الفرق بين VV و VH .
- المتوسط الشهري.
- الانحراف المعياري.
- القيم العظمى والصغرى.
- الخصائص النسيجية (GLCM) .
- الخصائص الزمنية متعددة الفترات.

المرحلة الخامسة: إعداد بيانات التدريب

يتم إنشاء عينات تدريبية تمثل مختلف أنواع المحاصيل باستخدام:

- الرفع الحقلي (Ground Truth) .
 - نقاط GPS .
 - حدود الحقول الزراعية.
 - الخرائط الزراعية.
 - صور الأقمار الصناعية عالية الدقة.
- ويتم تخصيص رقم تصنيف (Class ID) لكل نوع محصول.

المرحلة السادسة: تدريب نموذج التعلم الآلي

تم استخدام خوارزمية K-Means لتصنيف المحاصيل، نظرًا لقدرتها العالية على التعامل مع البيانات الرادارية والبيانات متعددة الأبعاد، بالإضافة إلى مقاومتها للضوضاء وتحقيقها دقة مرتفعة في التصنيف.

يقوم النموذج بتعلم العلاقة بين الخصائص المستخرجة وأنواع المحاصيل المختلفة، ثم يطبق هذه العلاقة لتصنيف جميع

بكسلات منطقة الدراسة.

المرحلة السابعة: المعالجة اللاحقة

بعد الانتهاء من عملية التصنيف يتم تحسين جودة الخريطة الناتجة من خلال:

- إزالة البكسلات الشاذة.
- تطبيق مرشح الأغلبية (Majority Filter).
- إزالة المناطق الصغيرة جداً.
- استبعاد المسطحات المائية والمناطق العمرانية عند الحاجة.

5. تقييم دقة التصنيف

تم تقييم أداء نموذج التصنيف باستخدام بيانات تحقق مستقلة لم تدخل في عملية التدريب، وذلك من خلال إنشاء مصفوفة الالتباس (Confusion Matrix)، والتي تُستخدم لمقارنة نتائج التصنيف مع البيانات المرجعية. وشملت مؤشرات التقييم ما يلي:


- الدقة الكلية (Overall Accuracy).
- دقة المنتج (Producer's Accuracy).
- دقة المستخدم (User's Accuracy).
- معامل كبا (Kappa Coefficient).
- الدقة (Precision).
- الاستدعاء (Recall).
- مؤشر F1-Score.

وتوفر هذه المؤشرات تقييماً شاملاً لجودة نموذج التصنيف ومدى موثوقية النتائج.

6. المخرجات

ينتج عن المشروع مجموعة من المخرجات المهمة، تشمل:

- صور Sentinel-1 الشهرية.
 - مجموعة الخصائص الرادارية متعددة الأزمنة.
 - خريطة تصنيف لأنواع المحاصيل الزراعية.
 - تقرير تقييم الدقة ومصفوفة الالتباس.
 - ملف تصنيف بصيغة GeoTIFF متوافق مع برنامج ArcGIS.
 - كود متكامل داخل Google Earth Engine لإعادة تنفيذ الدراسة بسهولة.
- وتسهم هذه المخرجات في دعم التطبيقات الزراعية المختلفة، مثل تقدير المساحات المزروعة، ومتابعة نمو المحاصيل، وإدارة الموارد المائية، والزراعة الدقيقة، والتخطيط الزراعي المستدام.



7. الخاتمة

أثبتت هذه الدراسة أن دمج بيانات الرادار متعددة الأزمنة Sentinel-1 مع تقنيات التعلم الآلي داخل منصة Google Earth Engine يمثل منهجية فعالة وموثوقة لتصنيف أنواع المحاصيل الزراعية بدقة عالية. كما تتيح منصة GEE معالجة كميات ضخمة من البيانات بسرعة وكفاءة، مما يجعلها أداة مناسبة للتطبيقات التشغيلية على المستويات المحلية والإقليمية. وتوفر خرائط التصنيف الناتجة معلومات مكانية دقيقة يمكن الاستفادة منها في دعم متخذي القرار، وتحسين إدارة الموارد الزراعية، وتعزيز الأمن الغذائي، وتطوير نظم الزراعة الذكية، بما يساهم في تحقيق أهداف التنمية الزراعية المستدامة.